



FeelTrack

*Analizzare il sentiment dei post sui diversi social media e
confrontarli tra loro*

VALENTINA PAOLILLO 0512114820
MATTIA CASTIELLO 0512120487

February 2025

Github:FeelTrack

Indice

1	Introduzione	4
2	Definizione del problema	5
2.1	Obiettivo	5
3	Raccolta, analisi e preprocessing dei dati	5
3.1	La scelta del dataset	5
3.1.1	Analisi del dataset	6
3.1.2	Preprocessing dei dati	7
4	Modelli di Machine Learning utilizzati	11
4.1	Implementazione del Codice	11
4.1.1	Logistic Regression	11
4.1.2	Random Forest Classifier	11
4.1.3	Linear SVC (Support Vector Classifier)	12
4.1.4	MLPClassifier (Multi-Layer Perceptron)	12
4.2	Risultati ottenuti	13
4.2.1	Logistic Regression	13
4.2.2	Random Forest Classifier	14
4.2.3	Linear SVC	14
4.2.4	MLPClassifier	15
4.3	Conclusioni	15
4.3.1	Accuratezza complessiva	15
4.3.2	Analisi delle metriche di precision, recall e F1-score	15
4.3.3	Scelta del miglior modello	16
4.3.4	Conclusione	16
5	EDA - Analisi Esplorativa dei Dati	17
5.1	Numero di like vs Sentiment label	17
5.2	Relazione tra numero di like, di commenti e di share	18
5.3	Like vs numero di follower per i vari 'Post Type'	19
5.4	Post Type Distribution by Sentiment Label	20
5.5	Heatmap of Correlations between Numeric Variables	21
5.6	Relazione tra Sentiment e Interazioni	22
5.7	Feature Importance	23
5.7.1	Feature Importance per Logistic Regression	23
5.7.2	Feature Importance per Random Forest	24
5.8	Usi pratici	24
6	Conclusioni	25
7	Librerie e strumenti	25
7.1	Librerie utilizzate	25
7.2	Strumenti utilizzati	25

1 Introduzione

Nell'era digitale, i social media giocano un ruolo centrale nella comunicazione e nella diffusione di contenuti. Ogni giorno, milioni di utenti interagiscono attraverso post, commenti e condivisioni, generando un'enorme quantità di dati testuali. Comprendere il sentiment e le emozioni espresse nei contenuti social è fondamentale per aziende, analisti e ricercatori, poiché permette di interpretare il coinvolgimento degli utenti e le dinamiche di interazione online. Il progetto FeelTrack si propone di sviluppare un sistema automatizzato per l'analisi delle emozioni nei testi pubblicati sui social media. Attraverso l'uso di tecniche di machine learning e analisi del linguaggio naturale (NLP), il sistema sarà in grado di classificare il sentiment dei post e analizzare il loro impatto in termini di interazioni, come like, commenti e condivisioni.

2 Definizione del problema

2.1 Obiettivo

L'obiettivo principale di FeelTrack è sviluppare un sistema automatizzato in grado di analizzare il sentiment e le emozioni espresse nei contenuti testuali dei social media. Attraverso l'impiego di modelli di machine learning e tecniche di analisi del linguaggio naturale, il progetto mira a classificare le emozioni presenti nei post e a valutare il loro impatto in base alle interazioni degli utenti, come like, commenti, condivisioni e numero di follower.

In particolare, FeelTrack si propone di:

- Implementare un modello di classificazione del sentiment basato su machine learning.
- Analizzare e visualizzare le emozioni espresse nei testi attraverso grafici e rappresentazioni statistiche.
- Studiare la correlazione tra il sentiment dei post e il livello di engagement degli utenti.
- Fornire insight utili per strategie di marketing, analisi di trend e comprensione del comportamento degli utenti sui social media.

3 Raccolta, analisi e preprocessing dei dati

3.1 La scelta del dataset

Venendo al dataset, necessario per la creazione del modello di machine learning, le possibili strade da seguire sono due:

- Creare un dataset da zero, formulando un questionario da far riempire ad un campione di persone, per poterne carpire le preferenze;
- Cercare sulla rete un dataset già formato, e adeguarlo alle nostre esigenze;

La prima opzione era soggetta a limitazioni non trascurabili:

- Scarsità dei dati
- Possibile inconsistenza dei dati, dovuta alle risposte degli utenti non sempre veritiere.

Si è deciso, pertanto, di procedere con la seconda soluzione, cercando in rete un dataset già creato.

Per lo sviluppo di questo progetto, sono stati utilizzati tre dataset dalla piattaforma Kaggle:

- Train (Per visualizzare il train bisogna andare nella cartella Sentiment Analysis e trovare il file Train.csv)
- Twitter Sentiment Dataset
- Social Media Sentiment Analysis Dataset

Il primo e il secondo dataset sono stati combinati per effettuare l'addestramento del modello. Questa unione ha consentito di ottenere un dataset più ampio e variegato, migliorando la capacità del modello di individuare pattern utili per il training.

Il terzo dataset è stato invece impiegato esclusivamente per la fase di test del modello. Questo approccio ha permesso di valutare le performance del sistema su dati non visti in fase di addestramento, garantendo una verifica oggettiva dell'accuratezza della classificazione del sentiment.

L'utilizzo di questi dataset ha contribuito alla creazione di un modello solido ed efficace nell'analisi del sentiment, con possibili applicazioni nell'ambito del trading basato sulle emozioni degli utenti.

3.1.1 Analisi del dataset

Social Media Sentiment Analysis

CAMPO	SIGNIFICATO
User	L'identificativo univoco dell'utente che ha pubblicato il contenuto.
Platform	La piattaforma di social media su cui è stato pubblicato il post.
Post	Il contenuto testuale del post sui social media, che rappresenta opinioni, reazioni o feedback degli utenti.
Hashtag	Gli hashtag associati al post, che riflettono i temi di discussione.
Sentiment	Il sentiment del post, classificato come Positivo, Negativo o Neutro.
Likes	Il numero di "mi piace" ricevuti dal post, che rappresentano il livello di engagement.
Shares	Il numero di volte che il post è stato condiviso, mostrando quanto ha risuonato con il pubblico.
Comments	Il numero di commenti ricevuti dal post, che indicano il livello di interazione.

Table 1: Descrizione dei campi del dataset.

Train

CAMPO	SIGNIFICATO
Id	Identificatore unico per ogni entry.
Body	Contenuto del testo o del post.
Sentiment Type	La classificazione del sentimento del testo (positivo,negativo, neutrale).

Table 2: Descrizione dei campi del dataset

Twitter Sentiment Dataset

CAMPO	SIGNIFICATO
clean_text	Contenuto del testo o del post.
category	La classificazione del sentimento del testo.

Table 3: Twitter Sentiment Dataset

3.1.2 Preprocessing dei dati

La formattazione dei dati è stata effettuata su più livelli ed in più fasi, al fine di eliminare dati rumorosi.

Caricamento e pulizia dei dati

I dataset utilizzati per l'addestramento e il test sono stati caricati utilizzando pandas.

Rimozione delle colonne non necessarie

Il dataset comprende dati che si riferiscono anche a informazioni di cui non interessa effettuare l'analisi. A fronte di ciò, si è avuta una fase di tagli verticali.

```
# Drop not used columns
train_pt1 = train_pt1.drop(columns=['Id'], axis=1)
```

Gestione dei valori mancanti

Eventuali valori nulli presenti nei dataset sono stati rimossi.

```
[ ] # Drop rows where any column has missing values
train = train.dropna()
test = test.dropna()
```

Pre-processing del testo

Poiché l'analisi del sentiment si basa su dati testuali, il contenuto dei post è stato elaborato con tecniche di Natural Language Processing (NLP).

Tokenizzazione dei dati

Suddivisione del testo in parole o frasi per facilitarne l'analisi. Dividiamo il testo in parole con `nltk.word_tokenize` e rimuoviamo i caratteri non alfabetici.

```
import nltk
nltk.download('punkt')

train['Body'] = train['Body'].apply(lambda x: " ".join(
    [re.sub('[^A-Za-z]+', '', token) for token in nltk.word_tokenize(x)]
))
test['Post Content'] = test['Post Content'].apply(lambda x: " ".join(
    [re.sub('[^A-Za-z]+', '', token) for token in nltk.word_tokenize(x)]
))
```

Rimozione delle stopwords

Eliminazione delle parole comuni (es. "il", "e", "ma") che non aggiungono valore semantico all'analisi.

```
from nltk.corpus import stopwords
nltk.download('stopwords')

stop = stopwords.words('english')
train['Body'] = train['Body'].apply(lambda x: " ".join(
    [word for word in x.split() if word not in stop]
))
test['Post Content'] = test['Post Content'].apply(lambda x: " ".join(
    [word for word in x.split() if word not in stop]
))
```

Lemmatizzazione

Conversione delle parole alla loro radice per ridurre la variabilità lessicale (es. "correndo" → "correre").


```

from nltk.stem import WordNetLemmatizer
nltk.download('wordnet')

lemmatizer = WordNetLemmatizer()
train['Body'] = train['Body'].apply(lambda x: " ".join(
    [lemmatizer.lemmatize(word) for word in nltk.word_tokenize(x)]
))
test['Post Content'] = test['Post Content'].apply(lambda x: " ".join(
    [lemmatizer.lemmatize(word) for word in nltk.word_tokenize(x)]
))

```

Pulizia del testo

Rimozione di caratteri speciali, numeri e punteggiatura per migliorare la qualità dei dati in ingresso.

```

import re

def contractions(s):
    s = re.sub(r"won't", "will not", s, flags=re.IGNORECASE)
    s = re.sub(r"can't", "can not", s, flags=re.IGNORECASE)
    s = re.sub(r"n't", " not", s, flags=re.IGNORECASE)
    s = re.sub(r"'re", " are", s, flags=re.IGNORECASE)
    s = re.sub(r"'s", " is", s, flags=re.IGNORECASE)
    s = re.sub(r"'ll", " will", s, flags=re.IGNORECASE)
    s = re.sub(r"'t", " not", s, flags=re.IGNORECASE)
    s = re.sub(r"'ve", " have", s, flags=re.IGNORECASE)
    s = re.sub(r"'m", " am", s, flags=re.IGNORECASE)
    return s

train['Body'] = train['Body'].apply(lambda x: contractions(x))
test['Post Content'] = test['Post Content'].apply(lambda x: contractions(x))

```

Vettorizzazione, Conversione Numerica e Bilanciamento dei Dati: Tecniche per una Rappresentazione Ottimale

Per rendere i dati adatti ai modelli di machine learning, sono state applicate operazioni di trasformazione. Grazie a queste operazioni, il dataset è stato

reso coerente e strutturato, permettendo ai modelli di machine learning di apprendere in modo efficace le caratteristiche dei dati e migliorare la capacità predittiva del sistema.

Conversione in formato numerico - Vettorizzazione

Le variabili testuali sono state convertite in rappresentazioni numeriche utilizzando tecniche di vettorizzazione come TF-IDF o word embeddings.

```
# Feature Extraction using TF-IDF
from sklearn.feature_extraction.text import TfidfVectorizer

# Init the TfidfVectorizer
tfidf_vectorizer = TfidfVectorizer(max_features=6000, ngram_range=(1, 2))

# Apply TF-IDF to vectorize the text
X_train_tfidf = tfidf_vectorizer.fit_transform(X_train)
X_test_tfidf = tfidf_vectorizer.transform(X_test)

print("\nShape of X_train_tfidf:", X_train_tfidf.shape)
print("Shape of X_test_tfidf:", X_test_tfidf.shape)
```

```
Shape of X_train_tfidf: (131792, 6000)
Shape of X_test_tfidf: (32949, 6000)
```

Calcolo dei Pesi delle Classi per Gestire lo Sbilanciamento nei Dati

Questo codice calcola i pesi delle classi per gestire lo sbilanciamento nel dataset di addestramento. Usa `compute_class_weight` di scikit-learn per assegnare un peso maggiore alle classi meno rappresentate e un peso minore a quelle più frequenti, creando un dizionario classe: peso. Questo aiuta il modello a evitare bias verso le classi dominanti.

```
# Compute class weight to contrast class imbalance
from sklearn.utils.class_weight import compute_class_weight

classes = np.unique(y_train)
class_weight = compute_class_weight(class_weight='balanced', classes=classes, y=y_train)
class_weight = {label: weight for label, weight in zip(classes, class_weight)}

print("Class Weight")
print(class_weight)

Class Weight
{'negative': 1.5255292796703361, 'neutral': 0.9807265854057835, 'positive': 0.7548094820822093}
```

4 Modelli di Machine Learning utilizzati

Al fine di effettuare la classificazione, si è fatto ricorso a 4 modelli, di seguito descritti.

4.1 Implementazione del Codice

Per il nostro progetto, abbiamo utilizzato diversi modelli di machine learning per classificare e analizzare i dati raccolti. L'implementazione si è basata sull'uso della libreria scikit-learn, con preprocessing dei dati per garantire la qualità delle informazioni utilizzate nei modelli. Abbiamo eseguito le seguenti fasi:

- **Addestramento dei Modelli:** Abbiamo implementato e addestrato diversi modelli, tra cui Logistic Regression, Linear SVC, Random Forest Classifier e MLPClassifier.
- **Valutazione delle Prestazioni:** Abbiamo calcolato metriche come accuratezza, precisione, recall e F1-score per confrontare i modelli.

4.1.1 Logistic Regression

- **Tipo:** Modello di classificazione lineare
- **Descrizione:** La regressione logistica è stata implementata per classificare i dati in base alle probabilità di appartenenza a una classe.

```
# Importing the LogisticRegression class
from sklearn.linear_model import LogisticRegression

# Logistic Regression
logistic_model = LogisticRegression(max_iter=1000, class_weight=class_weight, n_jobs=-1, random_state=42, verbose=verbose)

# Fit the model on training data
logistic_model.fit(X_train_tfidf, y_train)

# Predict on test data
y_test_pred_logistic = logistic_model.predict(X_test_tfidf)

# Logistic Regression Results
print("\n[Logistic Regression]")
print("Test Accuracy:", accuracy_score(y_test, y_test_pred_logistic))
print("Classification Report:\n", classification_report(y_test, y_test_pred_logistic))

# Show the heatmap
sns.heatmap(confusion_matrix(y_test, y_test_pred_logistic), annot=True, fmt='d', cmap='Blues')
plt.title("Confusion Matrix - Logistic Regression")
plt.show()
```

4.1.2 Random Forest Classifier

- **Tipo:** Modello di apprendimento ensemble basato su alberi decisionali
- **Descrizione:** è un algoritmo di ensemble learning che costruisce numerosi alberi decisionali su campioni casuali del dataset. Le predizioni

```

# Importing the RandomForestClassifier class
from sklearn.ensemble import RandomForestClassifier

# Random Forest
rf_model = RandomForestClassifier(n_estimators=256, max_depth=96, class_weight=class_weight, n_jobs=-1, random_state=42, verbose=verbose)

# Fit the model on training data
rf_model.fit(X_train_tfidf, y_train)

# Predict on test data
y_test_pred_rf = rf_model.predict(X_test_tfidf)

# Random Forest Results
print("\n[Random Forest]")
print("Test Accuracy:", accuracy_score(y_test, y_test_pred_rf))
print("Classification Report (Test Data):\n", classification_report(y_test, y_test_pred_rf))

# Show the heatmap
sns.heatmap(confusion_matrix(y_test, y_test_pred_rf), annot=True, fmt='d', cmap='Greens')
plt.title("Confusion Matrix - Random Forest (Test Data)")
plt.show()

```

di questi alberi vengono poi aggregate (ad esempio, tramite voto di maggioranza) per ottenere un risultato finale più accurato e robusto, riducendo il rischio di overfitting.

4.1.3 Linear SVC (Support Vector Classifier)

- **Tipo:** Modello di classificazione lineare
- **Descrizione:** Abbiamo testato Linear SVC per sfruttare la separazione dei dati attraverso iperpiani ottimali. Ha mostrato ottimi risultati.

```

# Importing the LinearSVC class
from sklearn.svm import LinearSVC

# SVC with a Linear kernel (SVC(kernel="linear"))
svm_model = LinearSVC(max_iter=1000, tol=0.001, class_weight=class_weight, random_state=42, verbose=verbose)

# Fit the model on training data
svm_model.fit(X_train_tfidf, y_train)

# Predict on test data
y_pred_svm = svm_model.predict(X_test_tfidf)

# SVM Results
print("\n[SVM]")
print("Test Accuracy:", accuracy_score(y_test, y_pred_svm))
print("Classification Report: \n", classification_report(y_test, y_pred_svm))

# Show the heatmap
sns.heatmap(confusion_matrix(y_test, y_pred_svm), annot=True, fmt='d', cmap='Blues')
plt.title("Confusion Matrix SVM")
plt.show()

```

4.1.4 MLPClassifier (Multi-Layer Perceptron)

- **Tipo:** Modello di rete neurale artificiale
- **Descrizione:** Abbiamo addestrato un MLP con più strati nascosti per riconoscere pattern complessi nei dati. Ha fornito risultati molto promettenti.

```

# Importing the MLPClassifier class
from sklearn.neural_network import MLPClassifier
from sklearn.preprocessing import LabelEncoder

# Create a LabelEncoder object
label_encoder = LabelEncoder()

# Fit the LabelEncoder on the target variable
label_encoder.fit(y_train)

# Transform the target variable to numerical labels
y_train_encoded = label_encoder.transform(y_train)

# MLP Classifier
mlp_model = MLPClassifier(hidden_layer_sizes=256, max_iter=500, learning_rate_init=0.001, early_stopping=True, random_state=42, verbose=verbose)

# Fit the model on training data with encoded target variable
mlp_model.fit(X_train_tfidf, y_train_encoded)

# Predict on test data (remember to encode y_test as well)
y_test_encoded = label_encoder.transform(y_test)
y_test_pred_mlp = mlp_model.predict(X_test_tfidf)

# Convert predictions back to original labels
y_test_pred_mlp_labels = label_encoder.inverse_transform(y_test_pred_mlp)

# MLP Classifier Results
print("\n[MLP Classifier]")
print("Test Accuracy:", accuracy_score(y_test, y_test_pred_mlp_labels))
print("Classification Report:\n", classification_report(y_test, y_test_pred_mlp_labels))

# Show the heatmap (use y_test_pred_mlp_labels)
sns.heatmap(confusion_matrix(y_test, y_test_pred_mlp_labels), annot=True, fmt='d', cmap='Blues')
plt.title("Confusion Matrix - MLP Classifier")
plt.show()


```

4.2 Risultati ottenuti

Dopo aver addestrato e testato i modelli, abbiamo ottenuto i seguenti risultati.

4.2.1 Logistic Regression

Accuratezza del 87%, buona interpretabilità ma performance limitate su dati complessi



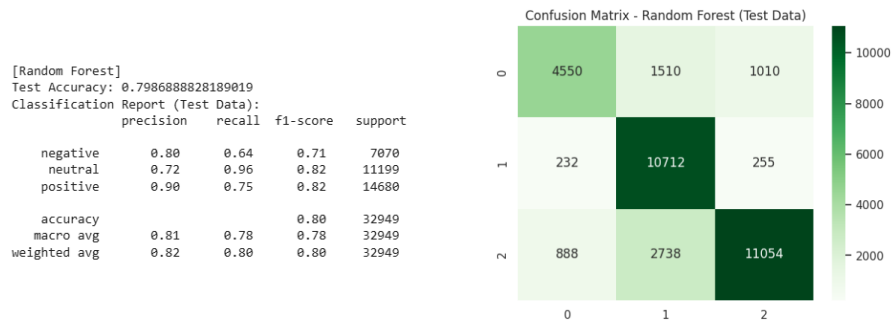
Osservazioni:

- Il modello sembra performare meglio nel predire correttamente i sentimenti "neutrali" (1), con una precisione e un F1-score più elevati.
- Il modello ha una buona capacità di identificare correttamente i sentimenti "positivi" (2), come evidenziato dall'alto valore di recall.

- La precisione nel predire i sentimenti "negativi" (0) è inferiore, suggerendo che potrebbe avere più difficoltà a distinguere tra "negativo" e "neutro".

4.2.2 Random Forest Classifier

Accuratezza del 80%, ottima capacità di generalizzazione e robustezza.




Osservazioni:

- Il modello è particolarmente bravo a identificare i sentimenti "positivi", con precisione e F1-score elevati.
- Il modello ha un'ottima capacità di identificare i sentimenti "neutrali" (1), come evidenziato dall'alto valore di recall.
- La precisione nel predire i sentimenti "negativi" (0) è inferiore, suggerendo che potrebbe avere più difficoltà a distinguere tra "negativo" e "neutro".

4.2.3 Linear SVC


Accuratezza del 88%, efficace su dati ben separabili ma con difficoltà su classi con meno campioni (come le negative e neutrali)



Complessivamente, il modello Linear SVC mostra buone prestazioni di classificazione, con un'accuratezza dell'88%. In particolare, il modello performa meglio nell'identificare le istanze "neutral" e "positive", mentre potrebbe avere qualche difficoltà in più con le istanze "negative".

4.2.4 MLPClassifier

Accuratezza del 88%.



Il modello MLP mostra buone prestazioni complessive e ottime prestazioni nella classificazione dei sentimenti neutri e positivi. Tuttavia, potrebbe avere qualche difficoltà nel distinguere i sentimenti negativi, come evidenziato dal recall inferiore rispetto alle altre classi.

4.3 Conclusioni

Dall'analisi dei quattro modelli presentati—Logistic Regression, Random Forest, SVC Linear e MLP Classifier—possiamo trarre le seguenti conclusioni:

4.3.1 Accuratezza complessiva

- **SVC Linear:** 88.41%
- **MLP Classifier:** 87.86%
- **Logistic Regression:** 87.05%
- **Random Forest:** 79.87%

L'**SVC Linear** ha l'accuratezza più alta, seguito da MLP e Logistic Regression; mentre, il Random Forest è il meno performante.

4.3.2 Analisi delle metriche di precision, recall e F1-score

- **SVM e MLP** hanno metriche molto simili e superiori agli altri due modelli, con valori più equilibrati tra precision e recall.

- **Logistic Regression** ha performance leggermente inferiori, ma ancora buone.
- **Random Forest** ha il valore di recall molto alto per la classe "neutral" (0.96) ma più basso per "negative" (0.64) e "positive" (0.75), rendendolo meno affidabile.

4.3.3 Scelta del miglior modello

- **SVC Linear** è il migliore in termini di accuratezza e F1-score medio (0.88), dimostrandosi il modello più bilanciato.
- **MLP Classifier** è un'ottima alternativa, con performance molto simili a SVC.
- **Logistic Regression** è una buona scelta se si vuole un modello più semplice e interpretabile.
- **Random Forest** è il peggiore in questo scenario, con performance meno bilanciate e accuratezza più bassa.

4.3.4 Conclusione

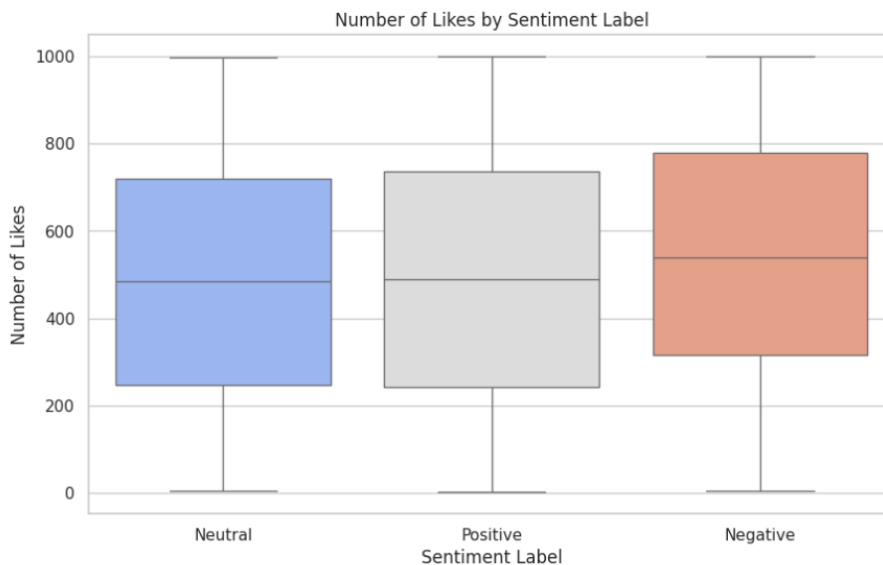
Dovendo scegliere un modello, SVC Linear sarebbe la scelta migliore, seguito da MLP Classifier.

5 EDA - Analisi Esplorativa dei Dati

L'analisi delle piattaforme social è cruciale per comprendere come gli utenti esprimono le loro opinioni e sentimenti in diversi contesti. Ogni piattaforma (Twitter, Facebook, Instagram, ecc.) ha caratteristiche uniche, sia per il pubblico che per lo stile di interazione. Analizzare il sentiment e il comportamento su ciascuna piattaforma ci permette di identificare differenze significative e trarre conclusioni strategiche per campagne di marketing o analisi sociali.

5.1 Numero di like vs Sentiment label

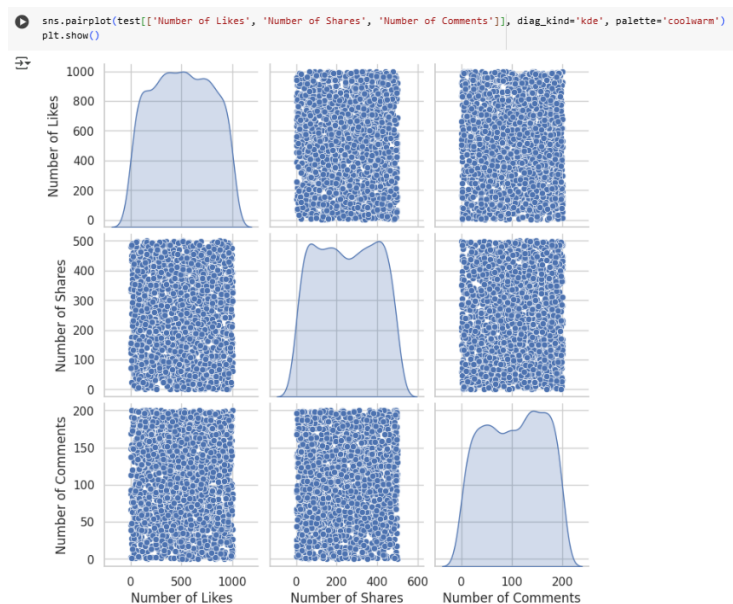
```
plt.figure(figsize=(10, 6))
sns.boxplot(x='Sentiment Label', y='Number of Likes', data=test, palette='coolwarm')
plt.title('Number of Likes by Sentiment Label')
plt.show()
```



Conclusioni:

- Il boxplot suggerisce che i post con sentimenti positivi tendono a ricevere più Mi piace rispetto ai post con sentimenti neutri o negativi.

5.2 Relazione tra numero di like, di commenti e di share




Conclusioni:

- Il pairplot suggerisce che esiste una relazione positiva tra il numero di Mi piace, il numero di condivisioni e il numero di commenti. I post con più Mi piace tendono ad avere anche più condivisioni e commenti.
- La distribuzione delle variabili suggerisce che ci sono alcuni post che spiccano per popolarità (outlier), con un numero di Mi piace, condivisioni e commenti molto elevato rispetto alla maggior parte degli altri post.

5.3 Like vs numero di follower per i vari 'Post Type'

```
plt.figure(figsize=(10, 6))
sns.scatterplot(x='User Follower Count', y='Number of Likes', hue='Post Type', data=test, palette='coolwarm', alpha=0.6)
plt.title('Number of Likes vs Follower Count by Post Type')
plt.show()
```




Conclusioni:

- Lo scatterplot mostra una relazione positiva tra il numero di follower di un utente e il numero di Mi piace che i suoi post ricevono, suggerendo che gli utenti con più follower tendono ad avere anche più Mi piace sui loro post.

5.4 Post Type Distribution by Sentiment Label


```
plt.figure(figsize=(10, 6))
sns.countplot(x='Sentiment Label', hue='Post Type', data=test, palette='coolwarm')
plt.title('Distribution of Post Types by Sentiment Label')
plt.show()
```



Conclusioni:

- Il count plot mostra che la distribuzione dei tipi di post varia a seconda del sentiment label. In particolare, sembra esserci una maggiore proporzione di video nei post con sentimenti positivi, mentre i post con sentimenti negativi tendono ad avere una maggiore proporzione di immagini.

5.5 Heatmap of Correlations between Numeric Variables



Conclusioni:

- La heatmap rivela correlazioni deboli o molto deboli tra le diverse metriche di engagement che stiamo analizzando. Questo significa che i cambiamenti in una metrica non predicono in modo affidabile i cambiamenti in un'altra.

Analisi più dettagliata:

- **Mi piace vs. altre metriche:**

Mi piace vs. condivisioni: Correlazione negativa molto debole (-0.015). Questo suggerisce che non c'è praticamente alcuna relazione tra il numero di Mi piace che un post ottiene e il numero di volte in cui viene condiviso.

Mi piace vs. commenti: Correlazione negativa altrettanto debole (-0.026). Anche in questo caso, indica che i Mi piace non predicono in modo affidabile il numero di commenti.

Mi piace vs. numero di follower: La correlazione negativa più forte (ma comunque debole) (-0.043). Ciò implica una leggera tendenza per i post di account con meno follower a ottenere leggermente più Mi piace, ma la relazione è molto debole.

- **Condivisioni vs. altre metriche:**

Condivisioni vs. commenti: Correlazione positiva molto debole (0.016). Quasi nessuna relazione.

Condivisioni vs. numero di follower: Correlazione negativa molto debole (-0.014). Di nuovo, praticamente nessuna relazione.

- **Commenti vs. numero di follower:**

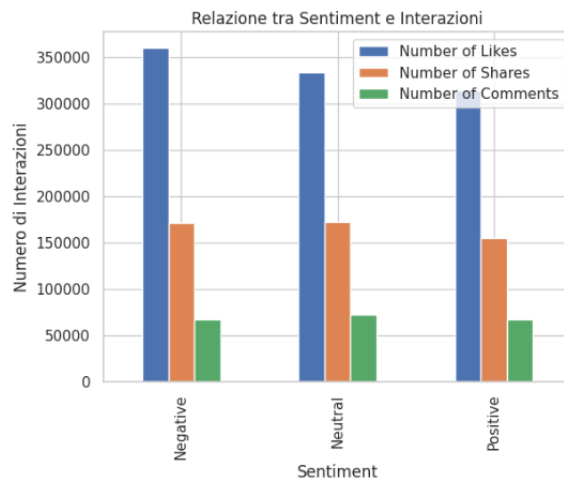
Correlazione negativa molto debole(-0.0045), quindi nessuna relazione.

5.6 Relazione tra Sentiment e Interazioni

```
# Assumiamo che i tuoi dati siano in un DataFrame Pandas chiamato 'df'
# Con colonne: 'sentiment', 'likes', 'shares', 'comments'

# Selezionare le colonne rilevanti
df_filtered = test[['Sentiment Label', 'Number of Likes', 'Number of Shares', 'Number of Comments']]

# Creare un grafico a barre raggruppate
df_filtered.groupby('Sentiment Label').sum().plot(kind='bar')
plt.title('Relazione tra Sentiment e Interazioni')
plt.xlabel('Sentiment')
plt.ylabel('Numero di Interazioni')
plt.show()
```



Conclusioni:

- Il grafico mostra chiaramente che esiste una forte relazione tra il sentiment di un post e il numero di interazioni che riceve.

Analisi dettagliata

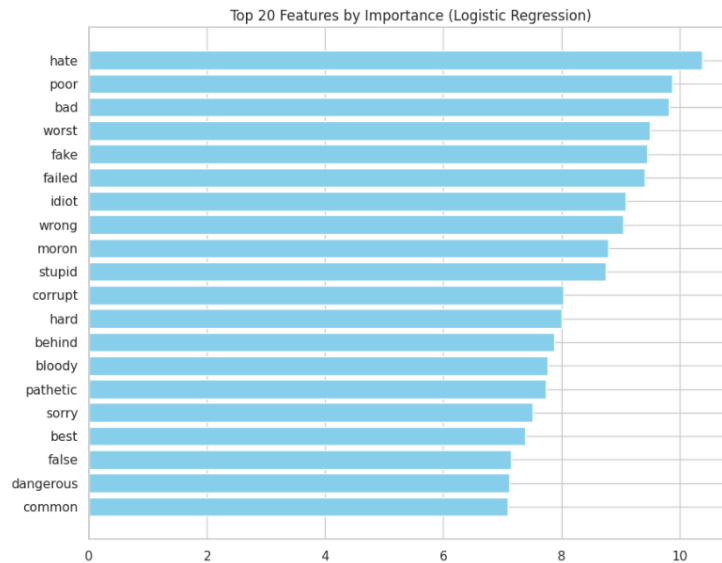
- Sentiment negativo: I post con sentimenti negativi tendono ad avere il minor numero di interazioni, soprattutto per quanto riguarda i Mi piace e le condivisioni.

- Sentiment neutro: I post con sentimenti neutri mostrano un numero di interazioni intermedio, con un leggero aumento rispetto ai post negativi.
- Sentiment positivo: I post con sentimenti positivi ricevono il maggior numero di interazioni in assoluto, con un picco significativo sia per i Mi piace che per le condivisioni.

5.7 Feature Importance

Si evidenziano le parole che hanno dato più peso alla determinazione del sentiment in particolar caso del Logistic Regression e Random Forest.


5.7.1 Feature Importance per Logistic Regression



Conclusioni:

- Il modello sembra essere molto sensibile alla presenza di termini negativi. Questo potrebbe indicare che il modello è efficace nell'identificare contenuti negativi o tossici.
- La presenza di alcune caratteristiche positive suggerisce che il modello non si limita a identificare il negativo, ma considera anche altri aspetti. Tuttavia, l'impatto di questi termini positivi è minore.
- L'analisi dell'importanza delle caratteristiche può fornire informazioni utili per migliorare il modello. Ad esempio, si potrebbe decidere di dare maggiore peso a determinate caratteristiche o di aggiungerne di nuove.

5.7.2 Feature Importance per Random Forest



Conclusioni

- Il modello Random Forest sembra essere efficace nell'identificare e dare peso a caratteristiche linguistiche e semantiche rilevanti. La predominanza di "modi" suggerisce che questa caratteristica cattura informazioni importanti per la distinzione tra classi o categorie.
- La presenza di parole con connotazioni positive o negative indica che il modello considera anche il sentiment o l'emozione espressa nel testo.
- L'analisi dell'importanza delle caratteristiche può fornire indicazioni utili per migliorare il modello. Ad esempio, si potrebbe decidere di concentrarsi su determinate caratteristiche o di crearne di nuove a partire da quelle esistenti.

5.8 Usi pratici

Questa analisi può fornire insight significativi:

- Per i brand: Comprendere dove concentrare le campagne promozionali basate sul sentiment positivo degli utenti.
- Per i sociologi: Esplorare come il tono delle conversazioni varia tra le piattaforme e cosa questo rivela sul comportamento sociale online.
- Per gli analisti: Identificare tendenze specifiche e prevedere come le piattaforme potrebbero evolversi nel tempo

6 Conclusioni

Il progetto FeelTrack ha dimostrato l'efficacia dell'analisi del sentiment sui social media attraverso l'impiego di modelli di machine learning. L'uso di dataset diversificati e tecniche di preprocessing avanzate ha consentito di ottenere modelli con buone performance, con l'SVC Linear e l'MLPClassifier che si sono distinti per accuratezza e capacità di generalizzazione. L'analisi dei dati ha evidenziato una forte correlazione tra il sentiment dei post e il livello di engagement degli utenti, confermando l'importanza delle emozioni nel determinare l'interazione sui social media. Inoltre, le tecniche di feature importance hanno permesso di individuare i termini chiave che influenzano maggiormente la classificazione del sentiment. Questi risultati dimostrano che FeelTrack può essere un utile strumento per aziende, ricercatori e analisti, fornendo insight preziosi sul comportamento degli utenti e sulle dinamiche di engagement nei social media.

7 Librerie e strumenti

7.1 Librerie utilizzate

- pandas: gestione e manipolazione dei dati
- numpy: operazioni numeriche e matriciali
- nltk: elaborazione del linguaggio naturale (tokenizzazione, stopwords, lemmatizzazione)
- sklearn (scikit-learn): implementazione di algoritmi di machine learning
- matplotlib: creazione di grafici e visualizzazioni
- seaborn: visualizzazione avanzata dei dati
- joblib: salvataggio e caricamento di modelli machine learning
- re: manipolazione e analisi di stringhe tramite espressioni regolari
- warnings: gestione degli avvisi e notifiche nel codice

7.2 Strumenti utilizzati

- Python: linguaggio di programmazione principale.
- Jupyter Notebooks: documentazione del processo e visualizzazione dei risultati.

8 Glossario

Sentiment Analysis

Tecnica di Natural Language Processing (NLP) utilizzata per identificare e classificare le emozioni espresse in un testo (positivo, negativo, neutro).

Engagement

Interazioni degli utenti con i post sui social media, tra cui like, commenti e condivisioni.

Hashtag

Parola o frase preceduta dal simbolo # utilizzata per categorizzare i contenuti sui social media.

NLP (Natural Language Processing)

Ramo dell'intelligenza artificiale che si occupa dell'interazione tra computer e linguaggio umano.

Tokenizzazione

Processo di suddivisione di un testo in unità più piccole, come parole o frasi, per facilitarne l'analisi.

Machine Learning

Tecnica di intelligenza artificiale che consente ai computer di apprendere dai dati e migliorare le proprie prestazioni senza essere esplicitamente programmati.

SVM (Support Vector Machine)

Algoritmo di machine learning utilizzato per classificazione e regressione.

Random Forest

Algoritmo di machine learning basato su alberi decisionali, utilizzato per compiti di classificazione e regressione.

Wordcloud

Visualizzazione grafica che rappresenta le parole più frequenti di un testo con dimensioni proporzionali alla frequenza.

Cross-validation

Tecnica utilizzata per valutare le prestazioni di un modello di machine learning, dividendo i dati in set di addestramento e validazione.

Preprocessing dei dati

Fase iniziale di un'analisi che prevede la pulizia, trasformazione e preparazione dei dati per l'uso.